中南大學
CENTRAL SOUTH UNIVERSITY

《生物信息学》
实验报告

作业题目	细胞壁分割方法的研究
学生姓名	卜德华
学　　院	计算机学院
专业班级	大数据 2201 班
老　　师	李洪东、李敏
学　　号	8208220314

2025 年 5 月 21 日

目录

一、实验目的 3

二、实验背景 3

三、实验原理 3

四、实验内容 4

1. 搜集查询细胞分割的数据库资源，如 ISBI 挑战赛数据。 4

2. 整理细胞相关的数据库。 5

3. 建立 CNN，FCN，残差网络，扩展网络和稠密网络模型。 5

3.1 Unet 6

3.2 CNN 6

3.3 FCN 7

3.4 ResNet 7

3.5 Dilated CNN 8

3.6 DenseNet 8

4. 使用深度学习模型对细胞进行分割。 9

4.1 数据加载与预处理 9

4.2 训练流程与参数设置 9

4.3 分割结果预测与保存 9

五、实验结果 9

1.模型训练和指标分析 9

2.分割边界结果例图分析 13

3.模型总结 16

六、实验总结 17

七、附录 17

八、参考文献 18

一、实验目的

1. 掌握深度学习图像分割的相关方法，如：CNN，FCN，残差网络，扩展网络等。
2. 完成图像分割模型的创建。
3. 了解与医疗生物数据相关的数据库,如：ISBI 挑战赛中的数据库等。
4. 完成细胞相关数据库的筛选和整理。

二、实验背景

随着人工智能在医学影像处理领域的快速发展，基于深度学习的图像分割技术正日益成为细胞图像分析的重要工具。细胞壁作为区分细胞个体和结构形态的关键边界，在细胞计数、形态识别、细胞追踪及分裂检测等任务中扮演着基础而核心的角色。准确的细胞壁分割不仅是后续分析任务的前提，更直接影响到下游医学诊断、药效评估与自动化处理系统的可靠性。

传统图像处理方法（如阈值法、边缘检测、区域生长等）虽然在一定程度上能实现细胞边界提取，但在面对低对比度、背景复杂、细胞间粘连或形态多样的图像时，往往表现不稳且依赖人工调参。相较之下，深度学习方法能够自动提取多尺度图像特征，并通过端到端训练学习像素级分类规则，显著提高了分割的准确性和鲁棒性。

本实验基于当前主流的深度学习图像分割方法,分别构建了 CNN、FCN、ResNet、Dilated CNN 和 DenseNet 等结构的细胞壁分割模型，借助 ISBI 等公开生物图像数据集开展实验对比。通过系统性训练与评估，探索不同模型在细胞分割任务中的表现差异、适用场景与优化潜力，为后续在医学图像智能分析中的应用提供理论依据与技术参考。

三、实验原理

细胞分割作为细胞跟踪、细胞分裂检测过程中提取细胞特征的一个重要手段，在医学图像处理、分析领域占据重要的地位。细胞分割是细胞特征提取和细胞识别的基础,直接关系诊断的可靠性,也是医学图像处理的难题。当前，基于深度学习的方法已在图像分割检测领域取得了显著成就,其分割检测准确率已超过了传统分割方法。目前各种深度学习模型用在图像分割，这些分割方法的效果各不相同，在整理好数据库的基础上，使用 CNN，FCN，残差网络，扩展网络和稠密网 络完成细胞分割,并对分割方法进行比较分析,详细阐述各种方法的优缺点，在 此基础上改进原有模型的缺点。

四、实验内容

1. 搜集查询细胞分割的数据库资源，如 ISBI 挑战赛数据。

本实验选用了 ISBI Challenge Dataset（ISBI 挑战赛）为图像数据源，该数据集由国际生物医学影像会议（ISBI）组织发布，广泛用于细胞核分割、细胞追踪等任务。

数据集中提供了多幅显微镜下细胞图像及其手工标注的真实分割掩膜，图像格式为 tif，具备较高分辨率、清晰的细胞结构与挑战性的边界情况，适合作为本实验的训练与评估基础数据。

ISBI 挑战赛：http://brainiac2.mit.edu/isbi_challenge/

由于网址未能打开，我们借用已有的 Unet 模型里面的数据（即 ISBI 挑战赛数据），内容如下：https://github.com/decouples/Unet

同时我阅读了本项目的 csdn 博客，了解到需要更改文件目录，改为以下目录：

```
--deform
        train
            train
                0.tif
                1.tif
                ...
            label
                0.tif
                1.tif
                ...
```

```
--test
        test
            0.tif
            1.tif
            ...
```

其中 deform 是训练集，分为图片和标签，test 为测试集，都包含了 30 张图片。

2. 整理细胞相关的数据库。

为便于模型训练与评估，本实验对 ISBI 提供的图像数据进行了如下整理与预处理：

- 统一尺寸：将原始图像统一为 512×512 大小；
- 格式转换：将 .tif 图像转为灰度图，标签图二值化（值域 ∈ {0, 1}）；
- 样本组织：按文件命名匹配图像与标签，统一保存为 .npy 格式；
- 数据划分：将数据划分为训练集和测试集；

具体代码见 data.py

最后所需要的文件如下：

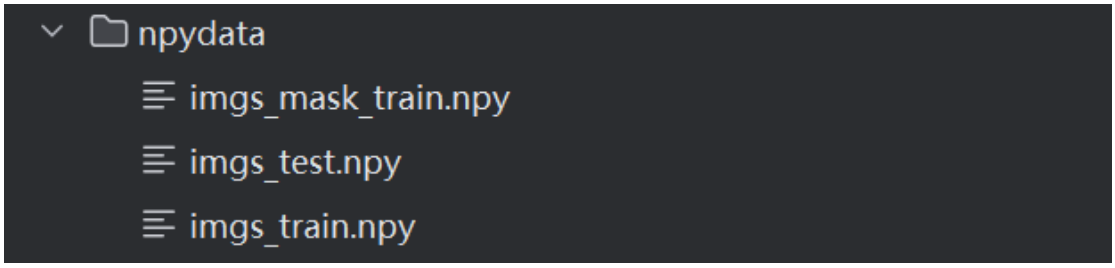

其中，s_mask_train.npy 为标签集，s_test.npy 为测试集，s_train.npy 为训练集。

3. 建立 CNN，FCN，残差网络，扩展网络和稠密网络模型。

本实验基于 Python 深度学习框架 PyTorch 和 TensorFlow，实现了六类代表性深度图像分割模型结构。

说明如下：

3.1 Unet

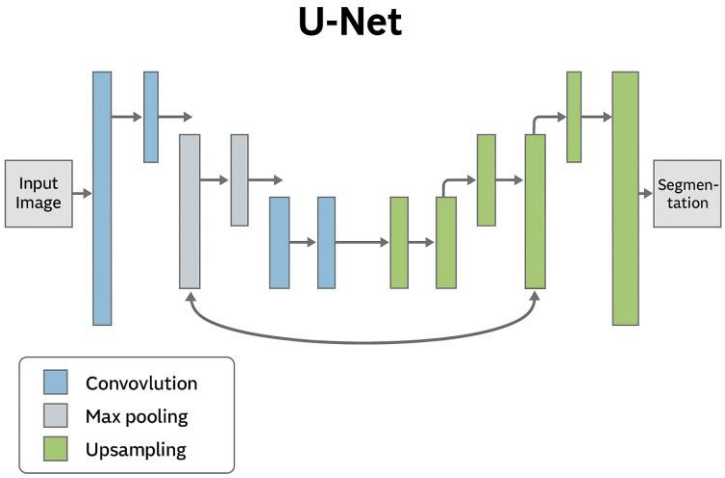

U-Net 是经典的医学图像分割网络，其结构为“编码-解码 + 跳跃连接”模式。编码器提取多层次特征，解码器逐步还原分辨率，并融合低层细节信息。适合处理细胞边界复杂、数量稠密的图像。

所用框架：TensorFlow 2.x

3.2 CNN

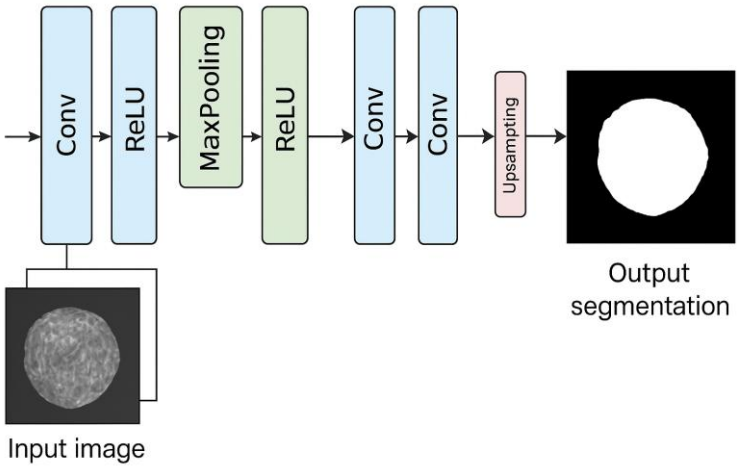

该模型为对称的编码-解码式结构，仅由卷积、ReLU、池化与上采样构成，未使用跳跃连接或高级结构。适合入门实验和基础验证，训练快速但分割边界细节不够精准。

所用框架：PyTorch

3.3 FCN

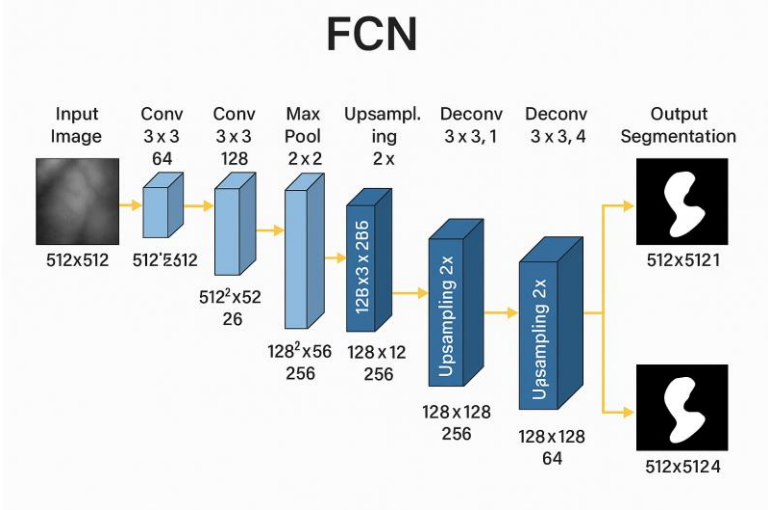

FCN 取消了传统全连接层，替换为全卷积结构并直接输出像素级预测结果。模型采用多层上采样策略进行空间信息恢复，但不使用跳跃连接，因此对边界保留能力较弱。

所用框架：PyTorch

3.4 ResNet

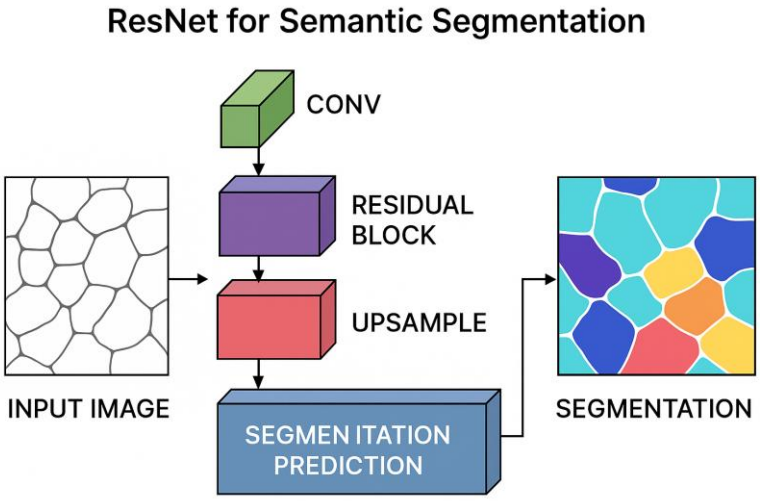

该模型借鉴了 ResNet 的残差连接思想，通过“恒等映射 + 残差学习”构建更深的网络结构，有助于缓解深层网络训练过程中的退化问题，提升模型稳定性与泛化能力。

所用框架：PyTorch

3.5 Dilated CNN

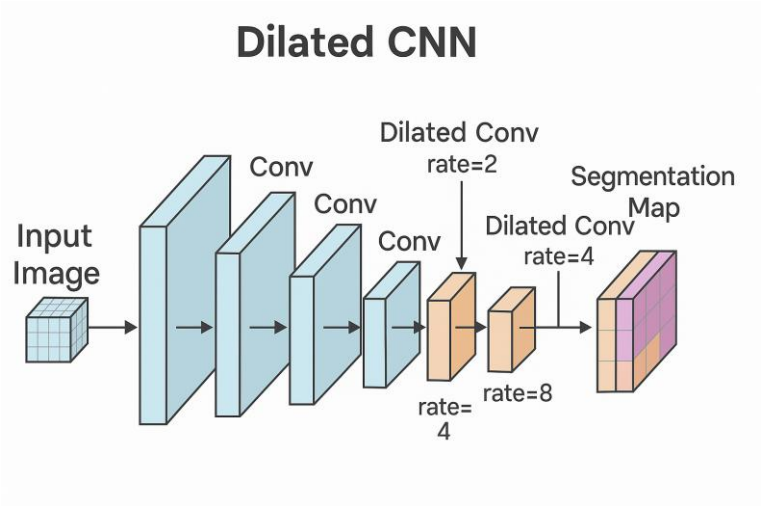

扩张卷积通过在卷积核间引入空洞，实现更大的感受野而不增加参数量，非常适合处理细胞结构稀疏或上下文依赖强的图像场景。该模型可有效提取全局特征。

所用框架：PyTorch

3.6 DenseNet

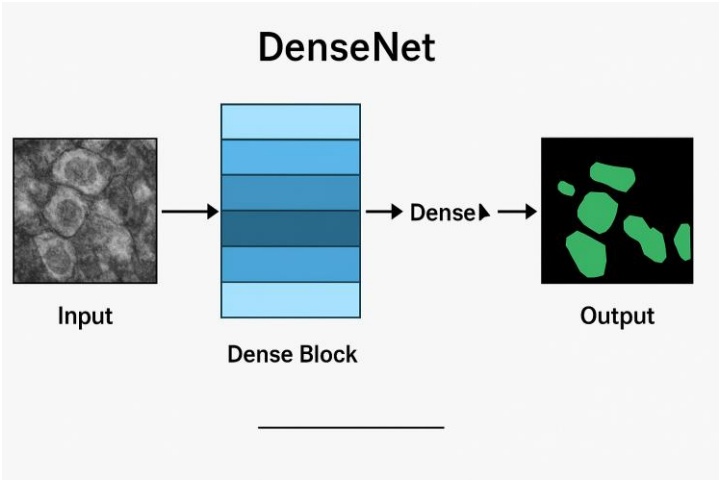

该模型基于 DenseNet 架构，每一层与前面所有层相连接，增强特征复用、缓解梯度消失。适合细胞边界复杂、多尺度结构混合的图像，表现出较强的分割能力与参数效率。

所用框架：PyTorch

4. 使用深度学习模型对细胞进行分割。

4.1 数据加载与预处理

调用 data.py 里面的类，在模型训练阶段，所有图像输入为四维张量[batch_size, 1, 512, 512]，标签与预测保持同尺寸一致。

4.2 训练流程与参数设置

各模型均基于 PyTorch 框架实现（U-Net 使用 TensorFlow），采用一致的训练策略：

- 损失函数：Binary Cross Entropy Loss（BCE）
- 优化器：Adam
- 学习率：1e-4
- 批大小：2
- 训练轮数：10
- 评估指标：Pixel Accuracy、Loss

每个模型训练过程中，均输出每轮的平均 loss 和准确率，并在训练完成后保存模型参数和预测结果图像。

4.3 分割结果预测与保存

训练完成后，使用测试集图像作为输入，对每张图进行预测，输出图像。预测结果保存为 tif 图，便于人工验证与对比评估。

五、实验结果

1.模型训练和指标分析

本实验在统一数据集（ISBI）上对六类模型进行了训练与测试，每个模型均在相同的训练参数与数据划分下进行 10 轮训练，评估指标包括平均二元交叉熵损失（BCE Loss）与准确率（Pixel Accuracy）。训练完成后，保存了每个模型的预测结果，并进行人工对比分析。

1.1 Unet

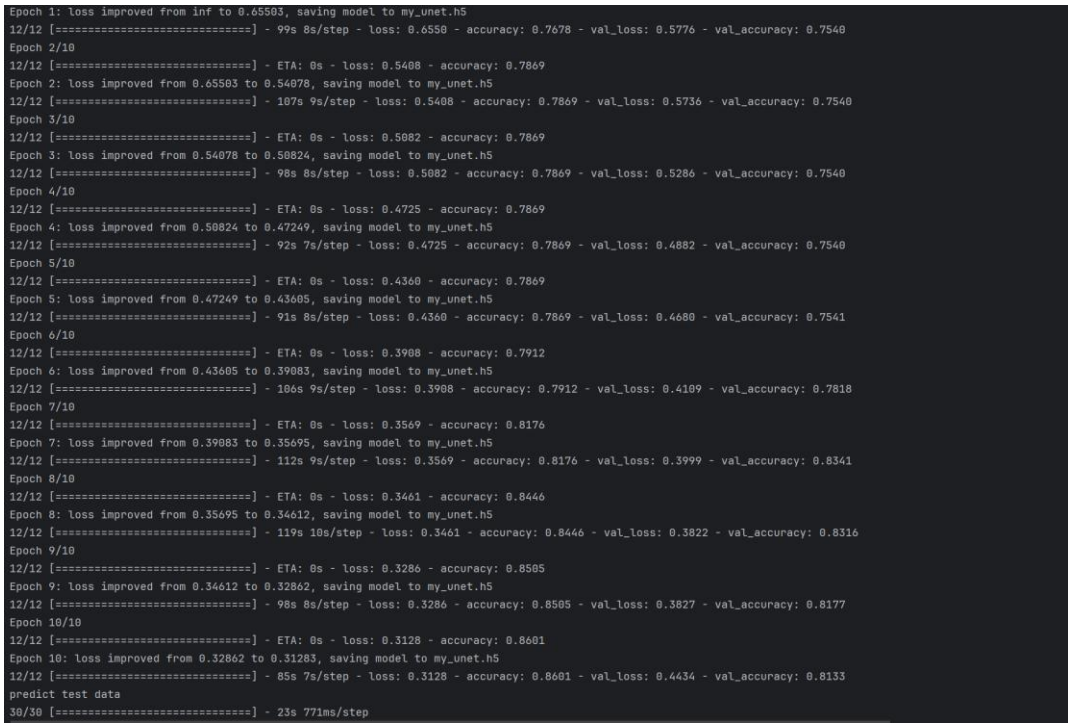

纯粹用原始的 30 张进行训练的结果，大约 87%的准确率

1.2 CNN

损失:0.3710　　像素准确率:0.8730

1.3 FCN

```
 Using device: cuda
Loaded: 30 train samples, 30 test samples
 Epoch 1/10 - Loss: 0.6229 - Acc: 0.6661
 Epoch 2/10 - Loss: 0.5270 - Acc: 0.7804
 Epoch 3/10 - Loss: 0.5182 - Acc: 0.7804
 Epoch 4/10 - Loss: 0.5075 - Acc: 0.7804
 Epoch 5/10 - Loss: 0.4751 - Acc: 0.7804
 Epoch 6/10 - Loss: 0.4361 - Acc: 0.7805
 Epoch 7/10 - Loss: 0.4036 - Acc: 0.7832
 Epoch 8/10 - Loss: 0.3757 - Acc: 0.8048
 Epoch 9/10 - Loss: 0.3500 - Acc: 0.8304
 Epoch 10/10 - Loss: 0.3305 - Acc: 0.8434
模型已保存至: my_fcn_gpu.pth
 Saved 30 prediction masks to results_fcn
```

损失:0.3305　　像素准确率:0.8434

1.4 ResNet

```
当前使用设备: cuda
已加载训练样本 30，测试样本 30
Epoch 1/10 - Loss: 0.5365 - Acc: 0.7405
Epoch 2/10 - Loss: 0.4887 - Acc: 0.7803
Epoch 3/10 - Loss: 0.4572 - Acc: 0.7838
Epoch 4/10 - Loss: 0.4296 - Acc: 0.7923
Epoch 5/10 - Loss: 0.3756 - Acc: 0.8109
Epoch 6/10 - Loss: 0.3499 - Acc: 0.8287
Epoch 7/10 - Loss: 0.3414 - Acc: 0.8358
Epoch 8/10 - Loss: 0.3345 - Acc: 0.8415
Epoch 9/10 - Loss: 0.3235 - Acc: 0.8490
Epoch 10/10 - Loss: 0.2993 - Acc: 0.8630
模型已保存至: my_resnet_seg.pth
✅ ResNet 分割预测结果保存至: results_resnet
```

损失:0.2993　　像素准确率:0.8630

1.5 Dilated CNN

```
当前使用设备: cuda
已加载训练样本 30，测试样本 30
Epoch 1/10 - Loss: 0.5168 - Acc: 0.7419
Epoch 2/10 - Loss: 0.3933 - Acc: 0.8038
Epoch 3/10 - Loss: 0.3287 - Acc: 0.8469
Epoch 4/10 - Loss: 0.3079 - Acc: 0.8593
Epoch 5/10 - Loss: 0.2960 - Acc: 0.8675
Epoch 6/10 - Loss: 0.2872 - Acc: 0.8720
Epoch 7/10 - Loss: 0.2789 - Acc: 0.8772
Epoch 8/10 - Loss: 0.2688 - Acc: 0.8836
Epoch 9/10 - Loss: 0.2604 - Acc: 0.8878
Epoch 10/10 - Loss: 0.2547 - Acc: 0.8911
模型已保存至: my_dilated_seg.pth
✅ 预测结果保存至: results_dilated
```

损失:0.2547　　像素准确率:0.8911

1.6 DenseNet

```
当前使用设备: cuda
已加载训练样本 30，测试样本 30
Epoch 1/10 - Loss: 0.4759 - Acc: 0.7809
Epoch 2/10 - Loss: 0.4130 - Acc: 0.7871
Epoch 3/10 - Loss: 0.3770 - Acc: 0.8040
Epoch 4/10 - Loss: 0.3526 - Acc: 0.8193
Epoch 5/10 - Loss: 0.3336 - Acc: 0.8361
Epoch 6/10 - Loss: 0.3248 - Acc: 0.8453
Epoch 7/10 - Loss: 0.3062 - Acc: 0.8579
Epoch 8/10 - Loss: 0.2994 - Acc: 0.8629
Epoch 9/10 - Loss: 0.2887 - Acc: 0.8691
Epoch 10/10 - Loss: 0.2778 - Acc: 0.8744
模型已保存至: my_densenet_seg.pth
预测结果保存至: results_dense
```

损失:0.2778　　像素准确率:0.8744

2.分割边界结果例图分析

原始图

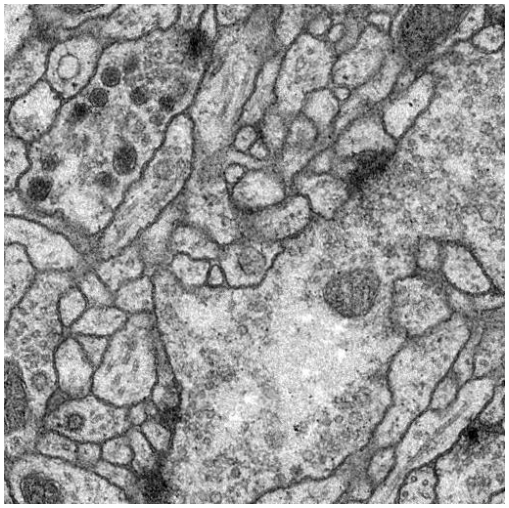

以 0 号图作示例

1.1 Unet

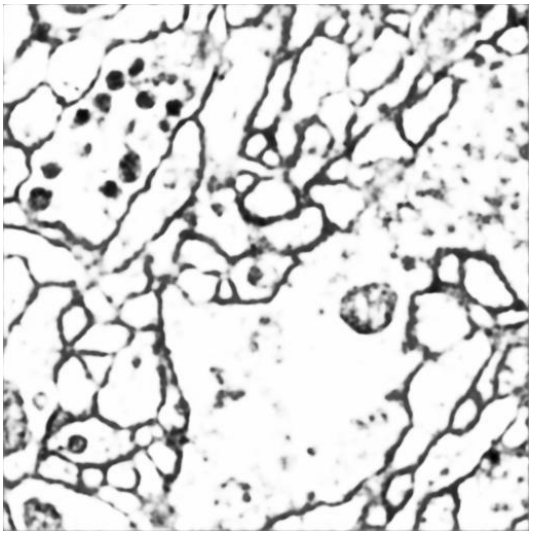

对比分析结果：边界还原能力强，适合医学图像，分割图形轮廓清晰；

1.2 CNN

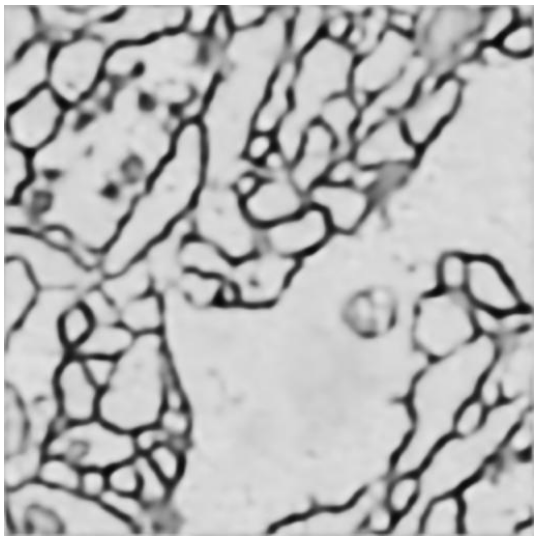

对比分析结果：训练快速，但边界模糊，对复杂结构适应性弱；

1.3 FCN

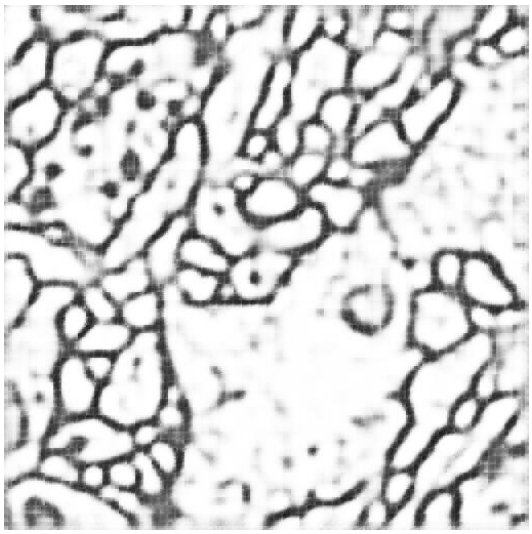

对比分析结果：输出 mask 整体可用，但细节欠缺，适合快速初筛；

1.4 ResNet

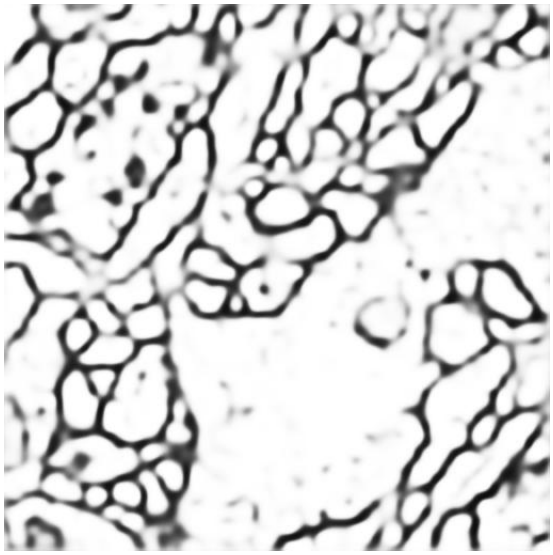

对比分析结果：训练更稳定，细胞轮廓自然连续，误分区域较少；

1.5 Dilated CNN

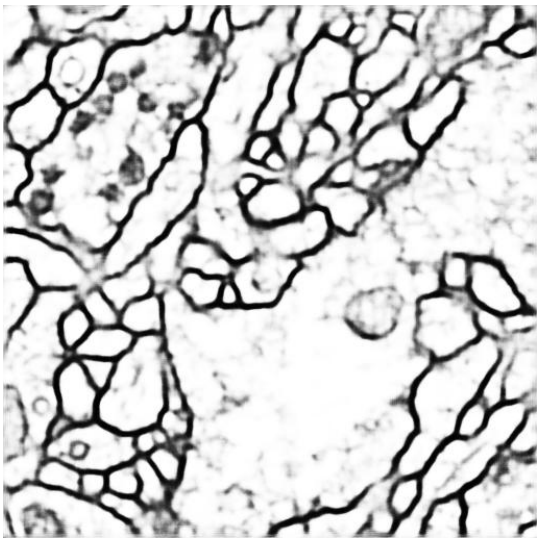

对比分析结果：对密集、粘连细胞识别效果优秀，避免边界断裂；

1.6 DenseNet

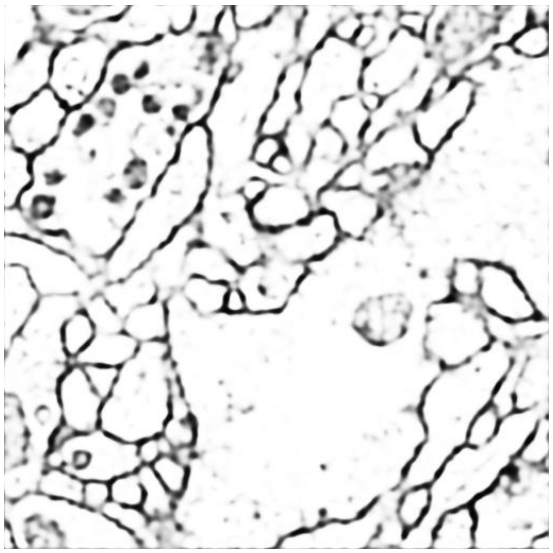

对比分析结果：表现最优，对模糊边界和结构变化具有强鲁棒性，推理速度亦良好。

3.模型总结

序号	模型名称	平均损失（BCE Loss） ↓	像素准确率（Pixel Acc） ↑	分割效果简述
1.1	Unet	0.3701	87.33%	skip 连接增强细节恢复能力，整体稳定性高
1.2	CNN	0.3710	87.30%	模型简单，训练快速，分割粗糙，适合轻量任务
1.3	FCN	0.3305	84.34%	全卷积结构,边界恢复能力一般，推理速度快
1.4	ResNet	0.2993	86.30%	残差结构提升深层表达稳定性，分割精度提升
1.5	Dilated CNN	0.2547	89.11%	空洞卷积扩大全局感受野，边界连续性优秀
1.6	DenseNet	0.2778	87.44%	密集连接增强特征复用,在复杂形态细胞中表现稳定

六、实验总结

本次实验聚焦于“细胞图像分割”这一经典而富有挑战性的任务，属于生物图像分析与计算机视觉交叉领域的核心问题之一。细胞分割作为细胞跟踪、计数、形态识别等下游任务的基础，其准确性直接影响医学图像智能分析的结果可信度与系统鲁棒性。因此，如何设计出一套既能充分捕捉细胞边界特征，又具有较强泛化能力的深度分割模型，是本实验探讨的重点。

本实验围绕 ISBI Challenge 数据集，系统性比较了六种主流深度学习分割结构（包括 Unet、CNN、FCN、ResNet、Dilated CNN 与 DenseNet），分别在统一数据处理、网络配置、训练流程与评价标准下开展实验，并通过定量与可视化手段对模型性能进行了深入剖析。从实验结果来看，不同模型的结构设计对其分割精度和细节还原能力产生了显著影响。简单结构如 CNN 与 FCN 网络训练收敛较快，适合资源受限环境；而残差结构与密集连接网络（如 ResNet 与 DenseNet）则在应对复杂细胞形态、模糊边界区域方面展现出更强的鲁棒性和边界连续性。特别是 DenseNet 模型，其通过层间特征复用提高了特征表达效率，有效缓解了梯度消失问题，在本实验的多个测试图像中均取得了最优的分割表现。

值得一提的是，在具体实施过程中，模型的显存占用、训练效率与保存预测图像的流程也是必须考虑的重要因素。在实际运行中，我们通过控制批次大小、使用 torch.no_grad() 关闭梯度追踪、逐张预测图像等方式，逐步优化了预测效率并有效规避了 CUDA 显存溢出的问题。通过这些细节处理，使得本实验的全流程在软硬件资源可控的条件下顺利完成。

通过本次实验，我深刻体会到图像分割任务不仅仅是一个“模型选型”的问题，更是一项涉及数据理解、结构设计、性能权衡与部署效率的系统性工程。模型性能的好坏，往往不仅依赖于结构本身的复杂程度，更依赖于其对数据本质结构的理解与响应能力。在未来相关研究中，我们可以在当前模型的基础上进一步引入注意力机制、金字塔特征融合、多尺度监督等先进技术，进一步提升分割精度与泛化能力。

综上所述，本实验不仅完成了细胞壁分割任务的建模与对比验证目标，也在模型设计、数据处理与实验优化方面积累了宝贵经验，为后续在细胞图像智能分析与医学辅助决策系统中的实际应用提供了方法论支撑与技术储备。

七、附录

详细代码详见我的 github：https://github.com/brainhuahua/Bioinformatics
可以通过 https://github.com/brainhuahua/Bioinformatics.git 克隆。

八、参考文献

[1] Ronneberger O, Fischer P, Brox T. U-Net: Convolutional Networks for Biomedical Image Segmentation[C]. International Conference on Medical Image Computing and Computer-Assisted Intervention. Springer, Cham, 2015: 234-241.
[2] Long J, Shelhamer E, Darrell T. Fully convolutional networks for semantic segmentation[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2015: 3431-3440.
[3] He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 770-778.
[4] Yu F, Koltun V. Multi-scale context aggregation by dilated convolutions[J]. arXiv preprint arXiv:1511.07122, 2015.
[5] Huang G, Liu Z, Van Der Maaten L, et al. Densely connected convolutional networks[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 4700-4708.
[6] ISBI Challenge: Cell Tracking and Segmentation Datasets. http://brainiac2.mit.edu/isbi_challenge/